# Conception d'une Modern Data Platform avec architecture Médaillon et développement d'une application Text-to-SQL basée sur l'IA

## Introduction

Les entreprises produisent aujourd'hui de très grandes quantités de données provenant de plusieurs systèmes opérationnels. Ces données constituent une ressource stratégique permettant de suivre les activités, de mesurer les performances et de faciliter la prise de décision. Cependant, leur exploitation reste souvent complexe en raison de leur volume, de leur diversité et des compétences techniques nécessaires pour les interroger.

Parallèlement, les progrès de l'intelligence artificielle permettent désormais aux utilisateurs d'interagir avec les données en utilisant le langage naturel. Au lieu d'écrire des requêtes SQL, il devient possible de poser une question en français ou en anglais et d'obtenir automatiquement la requête SQL correspondante ainsi que les résultats attendus. Cette approche rend l'analyse des données accessible à un public beaucoup plus large.

Dans ce contexte, ce projet propose la mise en œuvre d'une plateforme moderne de données (Modern Data Platform) reposant sur une architecture Médaillon (Bronze, Silver et Gold) ainsi que le développement d'une application Text-to-SQL permettant aux utilisateurs d'interroger les données en langage naturel.

## Problématique

Dans de nombreuses organisations, les données sont stockées dans des bases relationnelles mais restent difficiles à exploiter par les utilisateurs métiers qui ne maîtrisent pas le langage SQL. Les solutions traditionnelles nécessitent l'intervention d'équipes techniques pour produire les rapports ou répondre aux besoins analytiques, ce qui augmente les délais et limite l'autonomie des utilisateurs.

La problématique de ce projet consiste donc à concevoir une plateforme de données moderne capable d'automatiser l'ingestion, la transformation et la modélisation des données tout en offrant une interface conversationnelle permettant d'interroger les données en langage naturel grâce à l'intelligence artificielle.

## Objectif général

L'objectif principal de ce projet est de concevoir et de mettre en œuvre une Modern Data Platform permettant de centraliser les données, de les transformer selon une architecture Médaillon et de développer une application Text-to-SQL capable de convertir automatiquement les questions des utilisateurs en requêtes SQL afin de simplifier l'accès aux informations décisionnelles.

## Objectifs spécifiques

Les objectifs spécifiques consistent à concevoir une architecture moderne de données, automatiser les pipelines d'ingestion, mettre en place une architecture Bronze, Silver et Gold dans Snowflake, transformer les données avec dbt, orchestrer les traitements avec Dagster,

développer une interface utilisateur avec Streamlit et intégrer Snowflake Cortex AI afin de convertir les questions en langage naturel en requêtes SQL exécutables.

**Jeu de données**

Le projet s'appuiera sur la base de données **Wide World Importers**, proposée par Microsoft comme jeu de données de référence pour SQL Server. Cette base représente les activités d'une entreprise fictive de distribution et couvre plusieurs domaines tels que les ventes, les achats, les clients, les fournisseurs, les stocks, les commandes, les livraisons ainsi que les paiements. Elle comprend également une base transactionnelle (OLTP) et un entrepôt de données destiné à l'analyse, ce qui en fait un excellent cas d'étude pour les projets de data engineering et de Business Intelligence.

**Architecture technique proposée**

L'architecture retenue repose sur une chaîne complète de traitement des données.

Les données transactionnelles seront stockées dans **SQL Server**, qui jouera le rôle de système source. Les pipelines d'ingestion seront développés avec **DLT (Data Load Tool)** afin d'extraire automatiquement les données de SQL Server et de les charger dans **Snowflake**.

Dans Snowflake, les données seront organisées selon une architecture **Médaillon**. La couche **Bronze** contiendra les données brutes provenant directement de SQL Server sans transformation majeure. La couche **Silver** permettra de nettoyer les données, de corriger les incohérences, de normaliser les formats et d'appliquer les règles métier. Enfin, la couche **Gold** regroupera des modèles de données optimisés pour les analyses décisionnelles, les tableaux de bord et les requêtes des utilisateurs.

Les transformations seront développées avec **dbt**, qui permettra de versionner les modèles SQL, de documenter les transformations et de réaliser automatiquement les tests de qualité des données.

L'ensemble des traitements sera orchestré avec **Dagster**, choisi pour ses fonctionnalités avancées de gestion des pipelines, de surveillance, de reprise sur erreur et de visualisation des dépendances entre traitements.

Enfin, une application **Streamlit** constituera l'interface utilisateur. Celle-ci permettra aux utilisateurs de poser leurs questions en langage naturel. Les questions seront transmises à **Snowflake Cortex AI**, qui générera automatiquement une requête SQL adaptée au schéma de la base Gold. La requête sera ensuite exécutée dans Snowflake et les résultats seront affichés directement dans l'application sous forme de tableaux ou de graphiques.

**Déroulement du projet**

Le projet débutera par l'installation de SQL Server et le chargement de la base **Wide World Importers**. Une fois les données disponibles, les pipelines DLT seront développés afin d'alimenter automatiquement Snowflake.

La deuxième étape consistera à construire l'architecture Médaillon en créant les différentes couches Bronze, Silver et Gold. Les transformations métiers seront ensuite développées avec dbt afin de produire un modèle analytique fiable.

La troisième étape portera sur la mise en place de l'orchestration avec Dagster afin d'automatiser l'ensemble des traitements de données et de garantir leur exécution régulière.

La dernière étape concernera le développement de l'application Streamlit intégrant Snowflake Cortex AI. Cette application permettra à un utilisateur de poser des questions telles que « Quels sont les dix meilleurs clients par chiffre d'affaires ? », « Quel est le montant total des ventes par mois ? » ou encore « Quels produits génèrent le plus de bénéfices ? ». Cortex AI générera automatiquement les requêtes SQL correspondantes et retournera les résultats sans que l'utilisateur ait besoin de connaître le langage SQL.

**Résultats attendus**

À l'issue de ce projet, une plateforme moderne de données entièrement opérationnelle sera disponible. Les données de SQL Server seront automatiquement intégrées dans Snowflake grâce à DLT, organisées selon une architecture Médaillon et transformées avec dbt. L'ensemble des traitements sera orchestré par Dagster.

Les utilisateurs disposeront également d'une application Streamlit capable d'interroger les données en langage naturel grâce à Snowflake Cortex AI. Cette solution permettra de démocratiser l'accès aux données, de réduire la dépendance envers les équipes techniques et d'accélérer la production d'informations décisionnelles.